

Maestria en Data Science

Laboratorio de implementación III

—

Trabajo Final

—

Federico Richard

Julio 2025

Introducción y Estrategia General

El objetivo de este trabajo fue desarrollar un modelo de pronóstico de ventas para un conjunto específico de productos, con el fin de predecir la demanda del mes de febrero de 2020. A diferencia de un enfoque de modelo único, la estrategia adoptada fue la creación de un **ensemble híbrido basado en la segmentación de productos utilizando un enfoque simple desde el uso únicamente de enfoque hacia el producto (<product_id>)**.

Se partió de la hipótesis de que no todos los productos se comportan de la misma manera y, por lo tanto, no todos se benefician del mismo tipo de modelo. Algunos productos pueden tener un comportamiento estable y predecible con modelos simples, mientras que otros, con mayor volumen o volatilidad, pueden requerir modelos más complejos. La solución final implementa una jerarquía de tres modelos distintos, aplicando el más adecuado a cada segmento de productos.

Descripción del Modelo Final

A continuación, se detalla el pipeline completo, desde la preparación de los datos hasta la generación de la predicción final.

Dataset y Preprocesamiento

El proceso comienza con la carga y transformación de los datos crudos.

- **Fuentes de Datos:**
 - sell-in.txt: Contiene el historial de ventas (toneladas) por producto y período.
 - tb_productos.txt: Contiene metadatos de los productos.
 - product_id_aprededir201912.txt: Lista de los product_id para los cuales se debe generar una predicción para febrero del 2020.
- **Pasos de Preprocesamiento:**
 1. **Conversión de Fechas:** La columna periodo (formato YYYYMM) se convierte a un objeto datetime (timestamp) para facilitar el manejo de series temporales.
 2. **Filtrado:** Se conservan únicamente los registros hasta diciembre de 2019 y que corresponden a los productos de la lista a predecir.
 3. **Agregación:** Los datos se agrupan por timestamp y product_id para obtener el total de toneladas (tn) vendidas por producto cada mes, creando un dataset consolidado (df_monthly_product).

Arquitectura del Modelo: Un Ensemble Híbrido por Segmentos

El corazón del proyecto es un sistema de predicción que opera en tres niveles o "tiers". Para cada producto, el sistema intenta aplicar el modelo del primer tier. Si no es aplicable, pasa al segundo, y finalmente al tercero.

Tier 1: Regresión Lineal para "Productos Mágicos"

- **Concepto:** Un subconjunto de 33 productos, denominados MAGIC_PRODUCTS, fueron identificados como candidatos ideales para un modelo de regresión lineal simple. Se infiere que estos productos tienen un comportamiento histórico estable y patrones que pueden ser capturados por sus ventas pasadas, estos “productos mágicos” fueron aportados por el profesor en las clases.
- **Feature Engineering:** Para este modelo, se crearon features basadas en lags históricos. El target es la venta dos meses en el futuro ($t+2$). Las features son las ventas del mes actual (t_n) y las ventas de los 12 meses anteriores (t_{n-1} a t_{n-12}).
- **Entrenamiento:** El modelo LinearRegression de scikit-learn se entrena utilizando únicamente los datos de diciembre de 2018 de los MAGIC_PRODUCTS para predecir febrero de 2019. Este modelo entrenado se utiliza luego para predecir febrero de 2020 a partir de los datos de diciembre de 2019.
- **Aplicación:** Se aplica exclusivamente a los productos del listado MAGIC_PRODUCTS.

Tier 2: AutoGluon para Productos de Volumen

- **Concepto:** Para los productos que no son "mágicos", se selecciona un subconjunto de los 500 productos con mayor historial de ventas para ser modelados con AutoGluon. Esta librería de AutoML es capaz de encontrar modelos de series temporales complejos, pero es computacionalmente intensiva.
- **Preparación de Datos:** Los datos de ventas de estos 500 productos se convierten a un TimeSeriesDataFrame, el formato requerido por AutoGluon. Los valores faltantes se rellenan automáticamente.
- **Entrenamiento:** Se entrena un TimeSeriesPredictor de AutoGluon con la tarea de predecir los próximos 2 meses (`prediction_length=2`). Se establece un límite de tiempo de entrenamiento de 1 hora (`AUTOGLUON_TIME_LIMIT = 60*60`).
- **Aplicación:** Se utiliza para predecir las ventas de los 500 productos seleccionados.

Tier 3: Promedio Histórico

- **Concepto:** Para todos los productos restantes, que no son "mágicos" ni fueron seleccionados para AutoGluon, se utiliza un método de baseline robusto y simple: el promedio histórico.
- **Cálculo:** Se calcula el promedio de las ventas de los últimos 12 meses (`HISTORICAL_MONTHS = 12`), excluyendo los meses en los que las ventas fueron cero. Esto evita que los meses sin ventas "castiguen" la predicción.
- **Aplicación:** Es el modelo de último recurso, garantizando que cada producto tenga una predicción. Si un producto no tiene historial de ventas, su predicción es 0.

3. Justificación de las Decisiones y Pruebas Implícitas

El diseño del ensemble revela un proceso de experimentación implícito.

- **Segmentación vs. Modelo Único:** La decisión de usar tres modelos sugiere que un único modelo global (por ejemplo, AutoGluon para todos o Regresión Lineal para todos) no arrojó resultados óptimos. La segmentación permite aplicar la complejidad adecuada a cada tipo de producto.
- **Selección de "Productos Mágicos":** El hecho de que un listado de productos esté codificado (hard-coded) implica un análisis previo donde se identificó que estos productos respondían particularmente bien a un modelo de regresión simple, superando a modelos más genéricos.
- **difícil superar a un simple promedio:** Luego de casi mas de 150 pruebas resultaba difícil y casi imposible superar a un simple promedio histórico. Las pruebas remitieron a poder mejorar ese score con la introducción de modelos sencillos como autogluon y regresiones lineales. Por lo que elegir el ensemble fue la mejor táctica que a mí me sirvió.
- **Optuna para encontrar los parámetros ganadores:** Utilice la librería de Optuna para una vez seleccionado el enfoque de los modelos, buscar los mejores hiperparametros que optimizaran el score del modelo

5. Resultados, conclusiones, aprendizajes y opiniones finales

Resulta extraño experimentar y ver que la ejecución de 3 modelos super sencillos pudieron llevarme al 2do puesto de la competencia (al menos en el public score). Siendo sincero, jamás se me hubiese ocurrido generar este tipo de entrenamiento y predicción por mis propios medios, el avance de las clases me orientó a realizar estas pruebas por lo que me deja parado en un lugar incomodo donde me pregunto: ¿estaré listo para afrontar problemas de ciencia de datos reales como este? Es cuestión de seguir experimentando.

La organización en mis experimentos no ha sido de lo mas organizadas. Me encontraba en una nube de pruebas que avanzaban en un score prometedor, pero luego retrocedía varios pasos, la selección del mejor modelo me resulto difícil ya que a veces me encontraba que el envío de un score particular no coincidía con la prueba que había realizado entonces conectar modelo y envío me resulto en una nube de confusión debido a mi desorganización en los ensayos, es un gran aprendizaje para el futuro.